Difficulty GRPO

面向有限算力的难度感知数学推理训练

Qwen3.5-9B全参数强化学习
两卡实现、评测核验与负结果分析

项目摘要

研究在线题目选择能否提高GRPO训练效率。基于verl与vLLM，在同机两张A100 80GB上完成均匀U、在线A、冻结S、零探索E共8组真实训练，并对评测生成漂移、完整检查点与成本进行核验。

主要成果是可检查的实现与实验比较。固定200步测试终点，U为95.38±0.66%，A为95.25±0.52%；A额外消耗6.74%已记录卡时，未建立稳定泛化或效率优势。

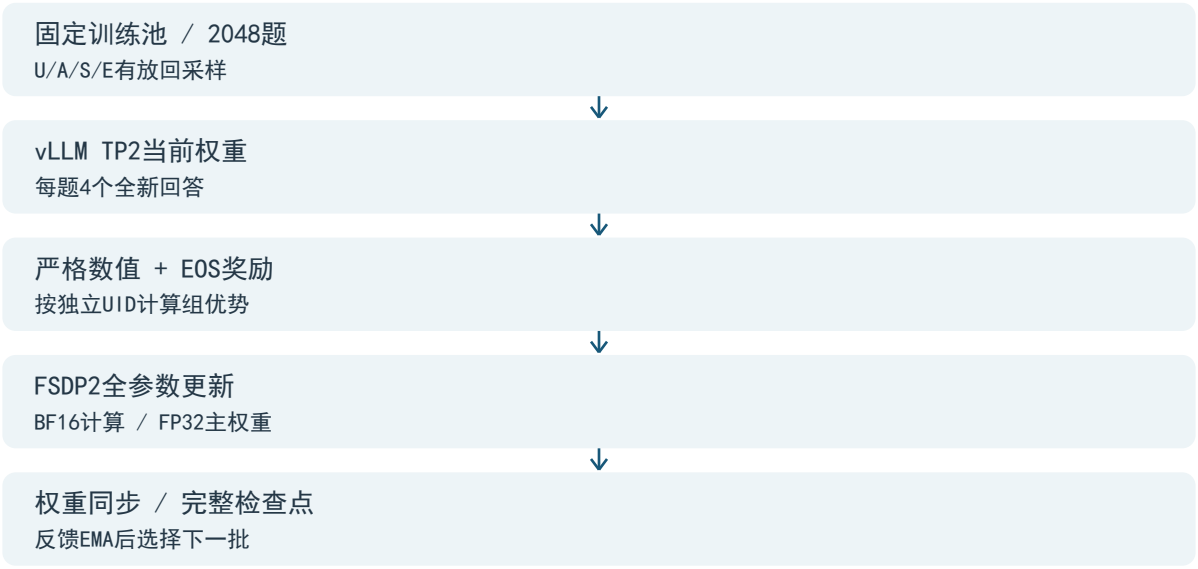
展示层级	事实边界
历史真实模型实验	以当前远程交接证据核对；本轮未重新训练/推理
本轮本地验证	标准Python演示、统计复算与CPU测试
业务/生产验证	无线上业务、用户实验或生产负载证据

整理日期：2026-11-06 | 作者与GitHub地址：未提供，不猜测署名

本报告对应独立公开候选。完整协议、来源哈希与剩余缺口随仓库提供；原实验目录与历史验收清单保持不变。

02 问题、目标与系统流程

全对或全错的二元奖励组缺少组内相对任务信号。项目尝试把更多预算分给当前策略成功率处于中间的题目，但必须同时检验覆盖、泛化与实际成本。



研究干预与对照

仅改变题目选择分布，模型、优化器、生成、奖励、损失与算法批量保持一致。U/A分别3个训练种子，S/E分别seed42。正式每组200步，前20步统一均匀。

同步训练与推理角色

vLLM承担当前策略rollout和推理缓存/调度；verl负责训练流程和GRPO优势，FSDP2负责参数分片和更新。actor更新后同步权重，再生成新轨迹。训练rollout是TP2，离线参考评测是TP1。

交付定位

使用者可读核心代码、无需GPU演示采样和恢复、复算公开成绩；具备GPU和依赖后可准备固定数据并运行新实验。公开包不包含权重，因此不能开箱加载原训练模型。

源码：dagrpo/sampler.py、train.py、full_engine.py、runner.py；完整架构见docs/ARCHITECTURE.md。

03 在线难度采样的实现

每题维护成功率p和访问次数，未访问题p=0.5。首次反馈直接取四回答平均正确率，此后EMA新观测权重0.3。

```
s_i = p_i * (1 - p_i)
A: q_i = 0.2/N + 0.8*s_i/sum(s)
E: q_i = s_i/sum(s)
sum(s)==0: uniform fallback
S: freeze p_i after the 20-update warmup
```

关键实现约束

题目有放回抽取；同题重复出现仍是独立回答组。上游在repeat前创建UID，反馈按UID聚合，不能按题目ID合并，也不能依赖重排后的相邻行。data loader的num_workers=0，下一批使用已更新统计。

只复用难度统计，不缓存旧回答。更新成功后反馈，再更新累计训练token、混合组与覆盖率。S冻结p但继续记访问数；E即便无探索也保留全零分数回退。

为什么p(1-p)只是代理

在独立Bernoulli回答假设下，4回答混合概率为1-p^4-(1-p)^4，在p=0.5最大。实际组内回答相关，历史EMA也有噪声/滞后；p(1-p)不等于真实混合概率。

优势与目标分布

全同奖励中心化后任务优势为0，KL loss仍可能有梯度。项目不做题目采样重要性校正，因此改变经验训练目标；不能称为对同一分布无偏提高效率。优势按组标准差归一化，loss按token-mean聚合，与原始按序列表述有实现差异。

接口：probabilities、feedback、state_dict、load_state_dict。CPU示例展示人造奖励与JSON状态恢复，不代表真实模型推理。

04 两卡全参数与可恢复工程

配置	采用值
模型与优化器覆盖	9,409,813,744可训练参数；760张量；LoRA rank=0
参数/计算	FP32主参数与Adam；BF16 GPU计算；FSDP2原生CPU卸载
算法/微批量	64题×4回答/更新；单卡微批量8；PPO epoch=1
训练	lr1e-6；clip0.2；KL loss0.001；梯度检查点
注意力	SDPA、FLA0.6.0；remove-padding=false；额外fused LM-head关闭

全参证据

引擎拒绝PEFT和冻结参数；检查全部可训练张量恰好进入优化器一次。两rank参数审计、有限梯度、嵌入/前中后层/LM head探针实际变化支持真实更新。不声称每个参数元素每一步都变化。

完整检查点提交

先保存研究sidecar，再由上游保存模型、Adam、数据/extra状态，最后发布complete.json。自动恢复仅选择完整点；研究状态包含采样器、访问次数、累计token、最佳点与driver Python/NumPy/Torch RNG。

历史2→3步恢复核验了Adam计数、采样位置128→192、下一批访问与随机流。此次同时切换FLA，属于工程验证，不是算法对照。正式八组固定FLA。vLLM内部全部随机状态的逐token连续性未获证明。

资源与保留策略

CPU卸载需要足够主机内存/带宽与大磁盘。短测约55GiB/卡为两秒采样峰值下界，不称显存打满；FLA算子11-13倍不等于端到端加速。正式save2，保留最新两份与最佳点；旧完整点会按既定策略清理，因此部分曲线无法重建。

05 数据、奖励与评测核验

数据/参数	口径
训练池 / 开发 / 测试	2048 / 512 / 1319；ID来自题目规范化哈希
拆分来源	官方train7473；固定seed42划dev再取训练池
prompt / response	512 / 1024 token；thinking=false
奖励	恰有一个最终####数值、正确且以EOS结束得1；其他0
参考解码	TP1/BF16/eager/greedy，128题分块；seed42

manifest中3879 ID互斥。本轮未重新采完整数据；公开模型可能接触基准，不主张零污染。数值归一化支持千位分隔、小数和负数；不做单位换算，不接收分数表达。格式错和非EOS可重叠，不能相加当作错误数。

greedy并不自动等于可复现

默认三次正确481、481、479/512，首次与第三次有67题token变化、4题判分变化。v2关闭引擎多进程后冷启动仍漂移；v3关闭异步调度且TP2时仍有200题token、6题得分差异。

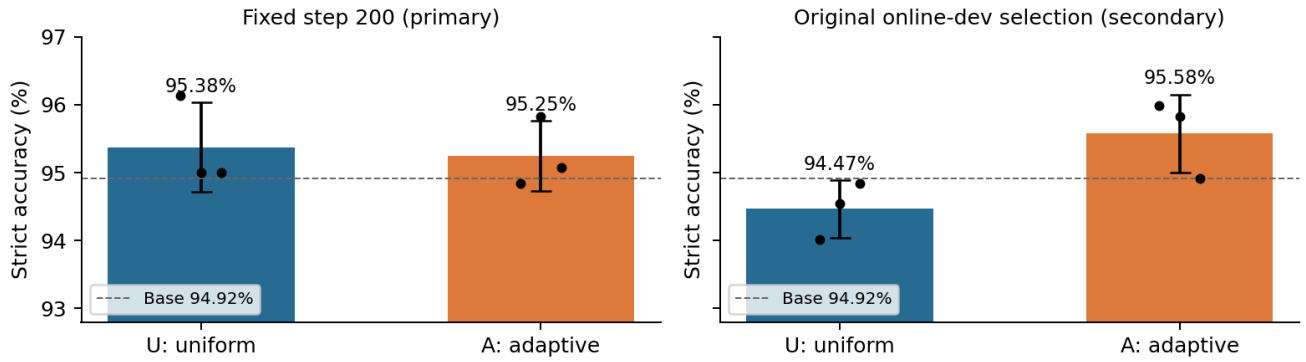
v4改TP1、禁用自定义多卡归约、eager、确定性设置、关闭TF32，固定PYTHONHASHSEED与cuBLAS工作区，禁用prefix cache/引擎多进程/异步调度。基座2进程×3次一致；训练权重dev双次及CLI冷启动核对后才复评。

冻结测试计划

测试前固化主次终点、数据ID/哈希、四份核心评测源码与17角色。基座test两张卡各冷启动一次一致，其余14训练权重test各一次；不保证跨硬件确定性。选点来自历史在线dev，不根据test重选。

06 主结果：收益随选点规则变化

GSM8K test: 1,319 shared items; n=3 training seeds; sample SD



Points = individual seeds. Project numeric/format/EOS scoring; no significance claim.

终点	U均值±样本SD	A均值±样本SD	A−U
固定step200	95.38±0.66%	95.25±0.52%	−0.13pp
原在线dev选点	94.47±0.42%	95.58±0.57%	+1.11pp

官方测试划分1319题，本项目严格评分；n=3训练种子，SD单位为百分点。基座94.92%。不是置信区间，不声称显著；同题跨模型重复不能当独立样本。

seed	U200正确数	A200正确数	差值pp
42	1268/1319	1251/1319	−1.29
43	1253/1319	1264/1319	+0.83
44	1253/1319	1254/1319	+0.08

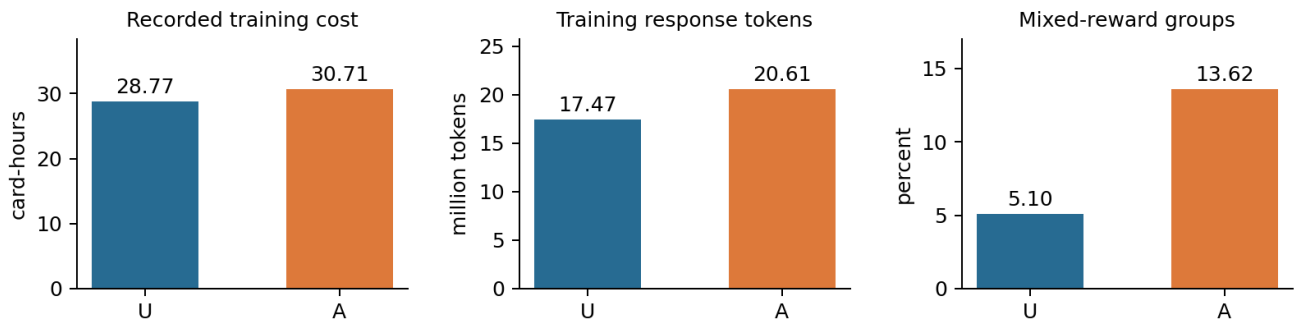
开发集与测试集必须分开

dev512参考固定终点：U93.82±0.11%，A94.86±0.11%；原在线选点参考复评U95.18±0.60%，A94.86±0.23%。不能将dev/test不同分母、不同协议的结果拼成提升曲线。

当前证据不支持“稳定泛化提升”。次终点更好且主终点无优势说明结论对选点敏感，不能只展示最好结果。公开标量评分可复算统计，但不是本轮新模型输出。

07 消融、成本与分布集中

Mean over three seeds; costs include recorded setup/resume/eval/save



More mixed groups did not establish a test or equal-budget efficiency advantage.

seed42	U	A	S	E
测试step200	96.13%	94.84%	94.69%	95.53%
末端零概率题	0	0	0	1892
最大单题概率	0.049%	62.55%	0.080%	99.68%
exp(熵)题数	2048	26.76	1514.88	1.04

A平均卡时比U多6.74%，训练回答token多17.94%；混合组均值5.10%→13.62%。增加代理信号不等于能力或效率提高。S/E只有单种子，不能外推一般优劣。

末端状态不是全程采样分布

快照位于200步反馈后、下一批选题前。20%探索只保证正概率，不阻止A剩余质量集中。E最后两步128次出现涉及79题，单题最多4次，不能由末端99.68%倒推出整段只练一道题。

成本解释

卡时包含已记账初始化、恢复、保存、在线评估与尝试；训练token只含回答。离线推理和控制器预留时间存在重叠，不能重复相加。重启次数不同也可能影响卡时。固定200步不能直接证明等卡时/等token效率。

08 真实迭代：组件分别记录

组件/阶段	改变与问题	验证 / 最终状态
模型候选	Qwen2.5-3B候选→Qwen3.5-9B；历史LoRA调试→全参	3B无正式训练证据；LoRA不计正式成果；9B全参采用
数据/输入	固定2048/512/1319；thinking=false与严格最终数值	ID/哈希与边界测试；采用；后续数据升级无
执行层	Ray绑定、NVML隔离、端口、前台.py、save2	回归测试与真实记录；平台兼容需要新环境再验
计算层	Torch回退→FLA0.6.0；32题计划→64题正式	BF16对照及真实模块审计；正式各组一致
采样算法	U / EMA在线A / 冻结S / 零探索E	8组200步；没有后续新算法版本
评测协议	默认→v2→v3→TP1参考v4	冷启动漂移排查后采用v4；不能视为算法提升
发布整理	新候选、README/来源映射/CPU示例/PDF	本轮本地检查；不是新训练或算法升级

保留历史问题与失败

实例中断前step8未有完整点，后以save2新目录重跑；旧消耗未抹去。默认和过渡评测结果只作历史探索，清理过的中间权重无法事后补造参考曲线。

归档控制脚本差异

历史archive-manifest与当前run_official_test.py哈希不同，未找到对应旧源码；68份可审核归档项中67匹配。四份冻结评分/推理核心与当前一致，结果文件也匹配。明确保留此版本缺口，不刷新历史清单，也不称控制器逐字可重放。

详细的“阶段→变化→问题→验证→是否采用”表见docs/ITERATION_HISTORY.md。项目没有主Git HEAD，不能补造原提交历史。

09 案例、展示与证据边界

奖励边界：单位等价也可能判错

历史dev案例中，模型正确得到1350分钟，再换算为22.5小时并以22.5作最终数值，会被严格答案1350判错。这是评分口径限制，不等于模型不会算时长。其他案例有折扣规则理解回退；不只挑成功回答。公开包不附原题/原回答，案例为历史报告的概括。

五分钟展示

```
python -B examples/sampler_demo.py
python -B tools/summarize_results.py
python -B tools/verify_release.py
```

先说明研究问题与负结果，再展示EMA概率、独立UID组与JSON恢复，随后复算1319题成绩，最后讲v4评测及来源映射。示例为人造奖励；现场演示不是模型推理，不启动GPU。

本轮验收与未运行项

私审包496文件完整性通过；3879 ID互斥；17角色/15权重的评分投影与源hash一致；68条原行样本重评分。CPU测试61项中53通过、8因缺训练依赖跳过。初次临时目录权限错误保留，迁到工作区临时目录后通过。

未执行SSH、依赖安装、下载、训练、GPU推理或重新加载大checkpoint。公开结果是派生摘要，不能代替独立重跑；权重SHA未知、跨硬件确定性未知、业务有效/生产可用未验证。

未来研究

可研究概率温度/上限、成功率先验和平滑、难基准及等预算试验，但本轮没有实现或验证。应另冻结开发/测试规则，不针对本次test反复调参。

10 复现路径、来源与许可

分层复现

层级	入口/条件
CPU	verify_release、sampler_demo、summarize_results；完整测试需matplotlib，训练集成按依赖跳过
环境	Linux；scripts/setup_cu129.sh；固定verl上游与CUDA版本；本轮未安装
数据	scripts/prepare_locked.py；固定模型/数据revision；空输出目录
真实训练	CLI pilot总steps保持200，但stop-after-step=2，续至3；成功再新目录phase full
评测	导出自有checkpoint；dev冷启动核验后冻结test计划；原权重不分发

来源与公开范围

远程私审包SHA256：
71547702137d69407406f33ac4b807c72d91dc81f313cb3ac9603c4fbb744a88

来源映射和提取规则位于provenance，严格文件清单位于RELEASE_MANIFEST.json。仅公开源码、配置、标量证据、图表和文档；不公开原始回答、部署地址/主机信息、凭据、模型/Adam、环境或完整数据。

固定资源与参考资料

verl v0.9.1：commit 1876b06d0a3e4e71e06230be10af14492ca8a75b；模型Qwen/Qwen3.5-9B：revision c202236235762e1c871ad0ccb60c8ee5ba337b9a；openai/gsm8k：revision 740312add88f781978c0658806c59bc2815b9866。完整可点击链接见dependencies.lock.json及third_party/THIRD_PARTY.md。

参考：verl固定core_algos.py（组优势实现）；vLLM reproducibility文档（https://docs.vllm.ai/en/latest/usage/reproducibility/）；GSM8K dataset card；Qwen缓存model card。外链未在本轮联网验证，结论依据已交接版本，不外推当前最新版本。

许可与贡献边界

候选根新增Apache-2.0，保留上游版权头及verl/Qwen许可副本。GSM8K缓存卡片标记MIT，不打包原数据。GRPO、模型、verl/vLLM/FLA归上游；新增工作是采样、全参工程、恢复审计、评测控制与分析。作者/仓库地址未提供；上传由用户手动完成。

完整命令与风险边界见README及docs/REPRODUCE.md；本PDF是发布说明，不替代原始私有证据。